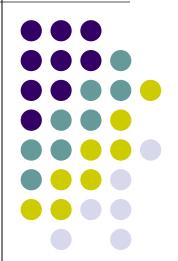
### Fiabilité des données

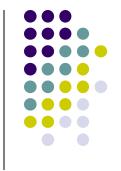


#### Introduction



- Constatations
  - Plusieurs milliers d' « utilisateurs » utilisent les données d'une BD de manière concurrente
  - La base de donnée n'est pas à l'abri d'une panne
- En conséquence
  - Le SGBD doit assurer
    - la cohérence des données
    - Fiabilité
    - Grâce à la notion de transaction

### Rappel sur les Transactions



- Suite d'actions comprises entre
  - Begin\_Transaction, qui marque le début d 'une transaction
  - et Commit\_Transaction, ou Abort\_Transaction, qui termine une transaction
- Exemple Typique : Begin\_Transaction

CpteA+=100;

CpteB-=100;

Commit\_Transaction

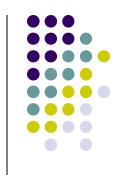
- cette suite d'actions répond aux propriétés ACID:
  - Atomicité : Tout ou rien
  - Cohérence : Données sont laissées dans un état cohérent
  - Isolation : Modifications pas visibles pendant la transaction
  - Durabilité : Les actions validées ne peuvent pas être perdues

#### **Atomicité**



- Notion :
  - Les actions d'une transaction sont indivisibles
- Besoins :
  - Pouvoir défaire des actions si elles ne sont pas validées
  - Pouvoir refaire des actions perdues après une Validation

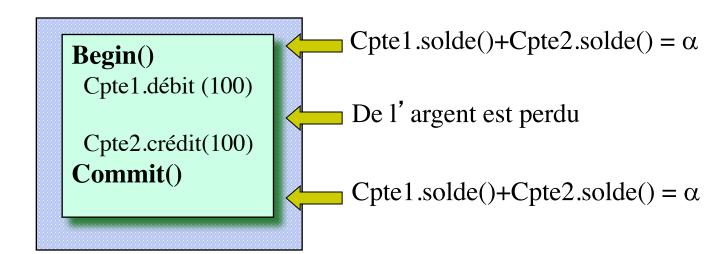




#### Notion

- Les données sont prises dans un état cohérent au début de la transaction, et rendues dans un état cohérent en fin de transaction
- La cohérence peut être violée au cours de la transaction

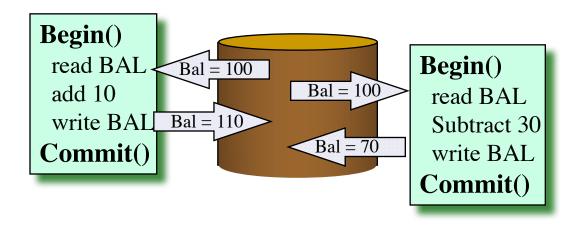
#### Exemple:







- Problème
  - Exécuter des programmes de manière concurrente peut amener à lire des données incohérentes
- Exemple

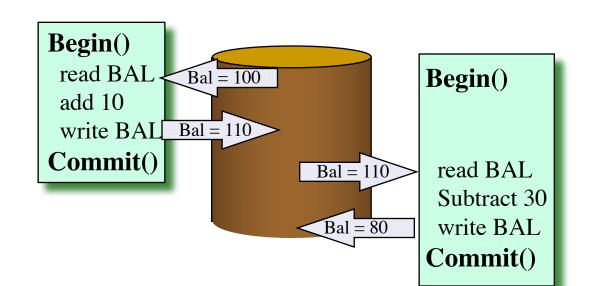






#### Besoins

- Les modifications d'une transaction ne doivent pas être visibles avant sa validation
- Un système transactionnel doit automatiquement protéger les applications (Verrouillage, Versionning, etc...)



#### Durabilité



- Notion
  - Les modifications effectuées par une transaction ne doivent pas être perdues
- Besoin
  - Système tolérant aux pannes (notion de sauvegarde)
  - Pouvoir refaire des transactions validées en cas de panne
- Plusieurs niveaux de durabilité
  - Le système tolérant à 100 % n 'existe pas
  - Exemple : impossible de faire des copies des données de carte à microprocesseur

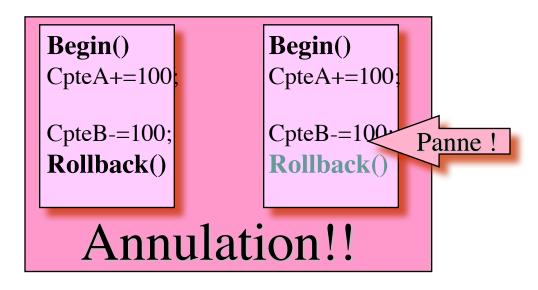
### Terminaison d'une Transaction



Seulement 2 possibilités :



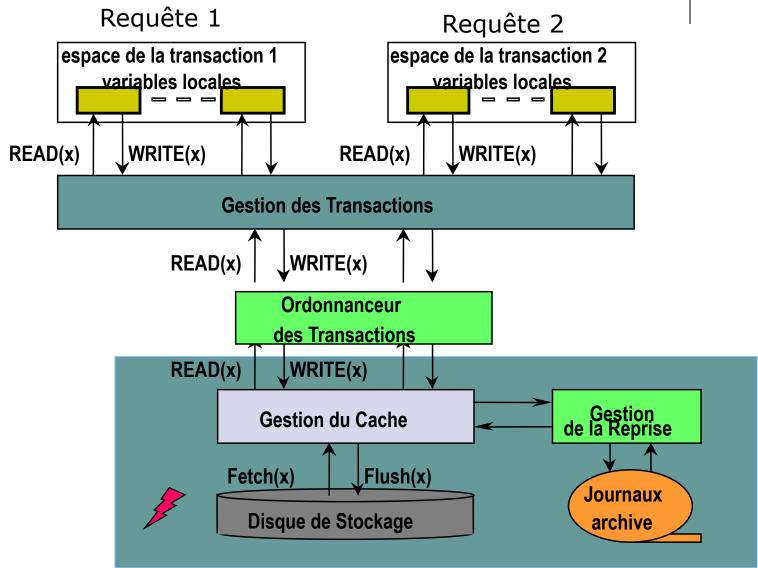
Les modifications sont Validées



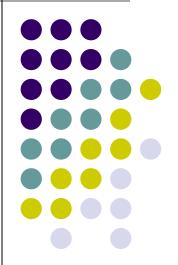
Les modifications sont Abandonnées

### Architecture du gestionnaire de données





# I. Le contrôle de concurrence



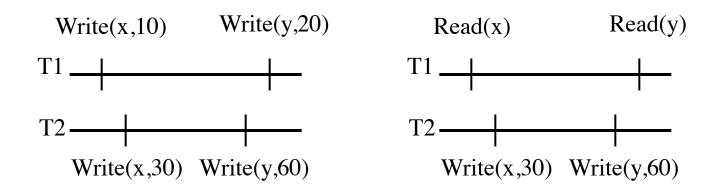
#### Au sommaire

- Gestion de la concurrence d'accès
  - Les situations d'incohérence
  - Principes à respecter
    - Serialisabilité
  - Notion de transaction
    - Définition
    - Propriétés
  - Techniques utilisées
    - Verrouillage à deux phases
    - Estampillage

### Notion de cohérence



 Une exécution concurrente non contrôlée de plusieurs transactions crée des incohérences :



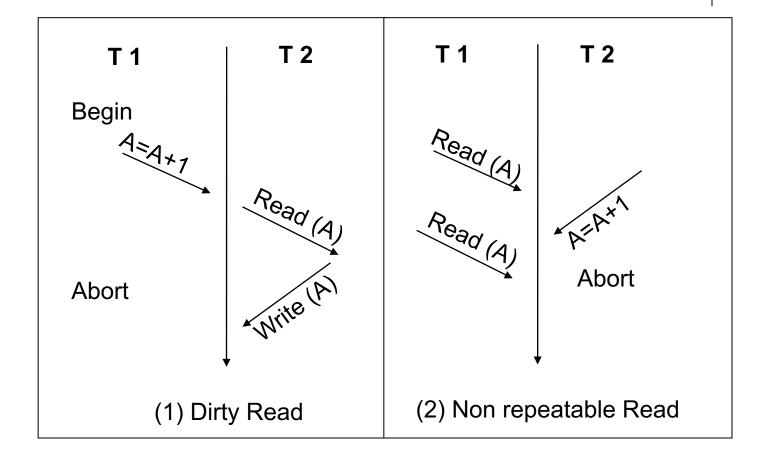
Ecritures incohérentes

Lectures incohérentes

### **Autres cas**



A=0



### Principe de Sérialisabilité

- Sérialisabilité d 'une exécution
  - = équivalence à une exécution en série des transactions
  - Exécution en Série :
    - « une exécution est dite en série, si pour tout couple de transactions, tous les événements de l'une précèdent tous les événements de l'autre »
  - Equivalence d 'exécution :
    - « 2 exécutions du même ensemble de transactions sont équivalentes ssi
      - elles sont constituées des mêmes événements
      - elles produisent le même état final des objets et les mêmes résultats pour les transactions »
  - Exécution sérialisable :
    - « Une exécution concurrente de transactions validées est sérialisable ssi il existe une exécution en série équivalente »

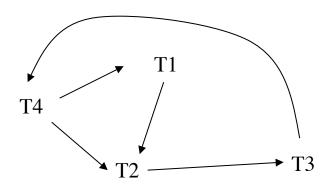


### Principe de Sérialisabilité (2)

- Exécution sérialisable commutable
  - Exécution commutable = cas particulier de sérialisable
  - op1 et op2 commutent si  $\forall$  (Ti, Tk) op1<sub>i</sub>(x)op2<sub>k</sub>(x) et op2<sub>k</sub>(x)op1<sub>j</sub>(x)
    - ont les mêmes effets sur x (produisent le même résultat)
    - ont les mêmes effets sur Ti et Tk (chaque transaction produit le même résultat)
- Exécution sérialisable stricte
  - Exécution stricte = cas particulier de sérialisable
  - Dès qu'une transaction a lu un objet, une autre peut lire le même objet, mais aucune autre ne peut écrire sur cet objet
  - Dès qu'une transaction a écrit un objet, aucune autre ne peut lire ou écrire sur cet objet

### Conflit et graphe de dépendance

- Conflit entre Transactions
  - Soient 2 transactions Ti et Tk, Un conflit existe si il existe un objet X accédé par Ti et Tk au moyen des opérations op1; et op2k telles que commute(op1, op2)
- Dépendance entre Transactions
  - Soient 2 transactions Ti et Tk, on a une dépendance de Ti vers Tk si il existe un conflit, et op1; < op2k</li>
- Graphe de dépendances
  - Permet de déterminer la sérialisabilité d 'une exécution concurrente



### Méthodes Pessimistes : le 2PL (1/2)



- Principe du Verrouillage à 2 Phases
  - N lecteurs XOR 1 seul écrivain
- A chaque accès à une donnée, un verrou est posé

Compatibilité	Lecture	Ecriture
Lecture	OUI	NON
Ecriture	NON	NON

- Les verrous sont tous relâchés à la fin de la transaction
- Inconvénient : risque de Dead Lock

### Méthodes Pessimistes : le 2PL (2/2)



- 2 phases:
  - Une phase d'acquisition des verrous
  - Une phase de libération
- Exemple:

T1	T2
1.Verrouiller (X, écriture)	2.Verrouiller (X, écriture)
3.Ecrire(X)	Ecrire(X)
4.Verrouiller(Y, écriture)	Verrouiller(Z, écriture)
5.Ecrire(Y)	Ecrire(Z)
6.Déverrouiller(X) Déverrouiller(Y)	Déverrouiller(X) Déverrouiller(Z)



### Méthodes Pessimistes : I 'estampillage (1/2)



- L 'Estampillage
  - Principes : utilisation de 2 estampilles L et M

Accès en Lecture à un Objet A par T	Accès en Modification à un Objet A par T
Si $V(T) >= M(A)$ alors	Si $V(T) >= max (M(A), L(A))$ alors
L(A) = max(V(T),L(A))	$\mathbf{M}(\mathbf{A}) = \mathbf{V}(\mathbf{T})$
sinon	sinon
Abandon de T	Abandon de T
fin si	fin si

- Avantage :
  - Facile à mettre en œuvre, pas d'interblocage possible
- Inconvénients :
  - Abandons inutiles
  - Possibilité pour une transaction de redémarrer indéfiniment

### Méthodes Pessimistes : I'estampillage (2/2)



#### • Exemple:

T1 Estampille = 1	T2 Estampille = 2	Estampille Obj	Observation
Lire(A)		Estampille =1	ОК
	Lire(A)	Estampille = 2	OK
	Ecrire(A)	Estampille =2	ОК
Ecrire(A)		Estampille =2	Impossible

### Méthode Optimiste : La certification (1/2)



Une transaction = 3 étapes



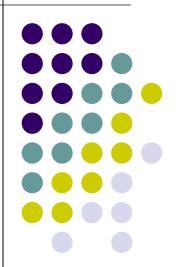
- Les transactions reçoivent une estampille en arrivant à la phase de certification
  - Si conflit, la transaction est relancée
  - Sinon, elle est validée : ces modifications sont recopiées dans la base

### Méthode Optimiste : La certification (2/2)



- Efficace si Tx faible de conflits :
  - si les conflits sont importants, il y a fort risque d'abandon
  - Cela consomme inutilement des ressources
- Les transactions ne doivent pas mettre à jour immédiatement la base (c'est à dire « salir » le support avant la validation) car :
  - Une transaction peut utiliser librement les effets d'une autre transaction pas encore validée
  - Cela peut conduire à des abandons en cascade
- Il faut utiliser un mode de mise à jour « différé »
  - espace de travail de la transaction <> espace de travail dans la BD

# II. La reprise sur panne



#### Au sommaire

- Principe
- Notion de Checkpoint
  - Rôle
- Méthodes
  - UNDO
  - REDO
  - UNDO/REDO
- Archivage



### **Contexte & définition**



- Définition:
  - Fiabilité d'une BD est l'aptitude du SGBD de préserver la cohérence en cas de la survenue d'une panne ou l'introduction d'erreurs
- Exemples d'erreur
  - Violation des contraintes d'integrité
    - Trigger
- Exemples de pannes
  - Crash disque
  - Défaillance du système (bugs, panne de courant)
  - Catastrophes naturelles

#### **Outils**

- Journaux
- Copie ombre
- RAID
- Sauvegarde multi-site

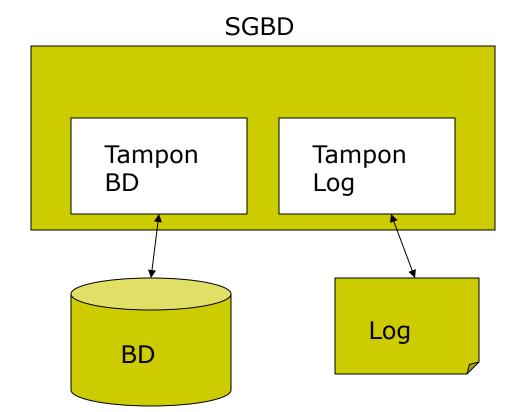
## Techniques de reprise sur panne



- Recouvrement:
  - à partir d'un journal (Log), reconstituer l'état cohérent de la base.
- Points de contrôle
  - Optimise la technique du recouvement
  - Contrôle régulièrement le contenu du fichier Log
- Archivage
  - utilisation de BD ombre

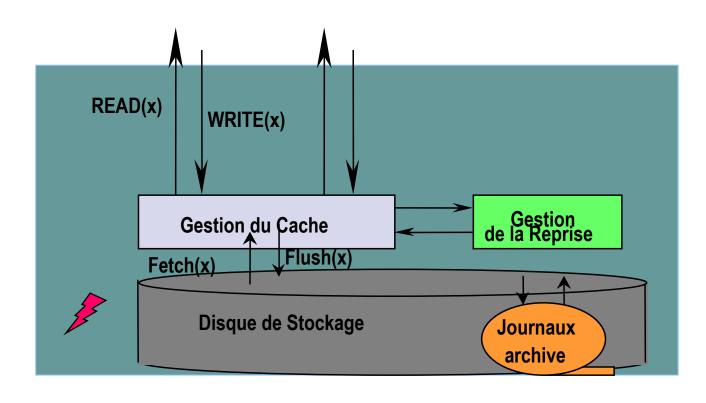
### **Gestion des Logs**





### La reprise sur panne & gestion cache





### Reprise sur panne & gestion cache



- Le SGBD utilise un cache pour minimiser les accès disque.
- Les données modifiées sont d'abord modifiées dans le cache
- puis stockés sur disque à la validation d'une transaction

Quelles sont les données valides?

-

### Les opérations élémentaires & utilisation de cache



- Read (x, buf) :
  - si x n' est pas dans le cache faire Input(x)
  - Buf:= x
- Write(x, Buf):
  - Si x n' est pas dans le cache faire Input(x)
  - X := Buf (en mémoire)
- Input (x) :
  - transfert de x du disque en mémoire
- Output(x):
  - Transfert de x de la mémoire vers le disque (mise à jour persistante)





- Exemple de tran
  - T1:
    - A=A+1;
    - B=B+2;

Op/ Saction	Buf	A	В	@A	B -@
				10	20
Read(A,Bu f)	10	10			
Buf+=1	11	10		10	20
Write(A,Bu f)	11	11		10	20
Read(B,Bu f)	20	11	20	10	20
Buf+=2	22	11	20	10	20
Write(B,Bu f)	22	11	22	10	20
Output A	22	11	22	11	20
Output B	22	11	22	11	22



### Le principe du recouvrement



- Le gestionnaire du recouvrement inscrit les événements dans un journal.
- Le journal est inscrit sur une mémoire stable : le disque
- En cas de panne, le journal servira à reconstituer la base de données dans un état cohérent.
- Le buffer du Log: évite le coût d'écriture sur disque à chaque mise à jour
- Respect des transactions validées (durabilité)

## Types d'événements journalisés



- <START T>:
  - au démarrage d'une nouvelle transaction
- <Commit T>:
  - A la validation de T
- <Abort T>:
  - En cas de rollback
- <T, A, v> :
  - Dans le cadre de la transaction T, l'ancienne (et/ou la nouvelle) valeur de l'attribut A est v

### Les points de contrôle



- Problématique
  - Le parcours de l'ensemble des événements depuis la dernière panne est lent et coûteux!!
- Technique
  - Vérifier à intervalle régulier la validité des transactions.
  - Laisser une trace dans le journal à chaque point de contrôle
  - Seuls les événements entre deux points de contrôle doivent être pris en compte
- Conséquence
  - Améliore considérablement le temps de recouvrement.

### La méthode de journalisation UNDO

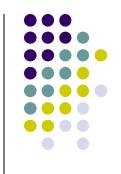


- Principe:
  - Permet d'annuler les effets des transactions non abouties
- fonctionnement:
  - <T,A,v>: A avait la valeur v sur disque avant une mise à jour effectuée par T
  - L'événement < commit T> ne peut être inscrit dans le journal qu'une fois les données modifiées sur disque
  - En conséquence, au commit de T:
    - 1. Flush() : permet de rendre persistant les écritures dans le journal pour une transaction
    - 2. Transfert des valeurs modifiées par T sur disque
    - 3. Ecrire < commit T > dans le journal
    - 4. Flush()

### **Exemple**

Op/mem	Buf	Α	В	@A	@B	cache	Sur disque
•							
				10	20	<start t=""></start>	<start t=""></start>
Read(A,Buf)	10	10					
Buf+=1	11	10		10	20		
Write(A,Buf)	11	11		10	20	T 4 10	.T A 10.
Read(B,Buf)	20	11	20	10	20	<1,A,10>	<t,a,10></t,a,10>
Buf+=2	22	11	20	10	20		
Write(B,Buf)	22	11	22	10	20		
Flush()						✓T D 20 \	∠T D 20 \
Output A	22	11	22	11	20	─ <t,b,20></t,b,20>	<t,b,20></t,b,20>
Output B	22	11	22	11	22		
Flush()							

#### Procédure de reprise



- Pour chaque transaction T démarrée avant panne:
  - Si commit T sur disque
    - Rien
  - Sinon
    - Pour chaque inscription <T,A,v>, restaurer la valeur v dans A sur disque
    - Inscrire <Abort T> sur journal
    - Flush()

## Technique des points de contrôle pour la methode UNDO



- Contrôle effectué à intervalles réguliers
- But :
  - Simplifier le recouvrement
- Une nouvelle inscription dans le Log:
  - <CKPT>
- Effet:
  - Recenser les transactions actives.
- Mise en œuvre
  - Soit T<sub>A</sub> cet ensemble
  - Jusqu'à la fin du point de contrôle, différer toute nouvelle transaction.
  - Attendre que toute transaction de T<sub>A</sub> soit fini et l'evenement abort ou commit inscrit sur journal
  - Effets sur le Log
    - flush()
    - Ecrire un <CKPT>
    - Flush()

# Procédure de reprise améliorée



- La reprise commence à partir du dernier point de contrôle
  - Lire le journal à partir de la fin jusqu' à <CKPT>.
  - Seules les transactions ayant démarré apres le CKPT sont à défaire
- Inconvénient du ckpt:
  - Blocage des transactions nouvelles
- Inconvénient de la journalisation UNDO
  - Oblige à réécrire systématiquement sur disque
  - N' optimise pas les E/S

# La méthode de journalisation REDO

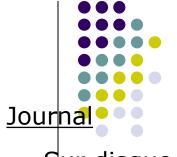


#### Principes:

- La reprise consiste à refaire les transactions validées à partir du journal et ignorer les autres
- <T,A,v>: signifie que la nouvelle valeur de A modifiée dans le cadre de T est v
- L'événement < commit T> sera inscrit dans le journal avant toute modification sur disque
- En conséquence:
  - Un flush() sur disque du journal avant toute écriture sur disque

### **Exemple**

O12 /122 2 122	Dur	Ι,	П		@D	
Op/mem	Buf	A	В	@A	@B	
				10	20	
Read(A,Buf)	10	10				
Buf+=1	11	10		10	20	
Write(A,Buf)	11	11		10	20	
Read(B,Buf)	20	11	20	10	20	
Buf+=2	22	11	20	10	20	
Write(B,Buf)	22	11	22	10	20	
Flush()						
Output A	22	11	22	11	20	
Output B	22	11	22	11	22	
Flush()						



cache Sur disque

<Start T><Start T>

<T,A,11> <T,A,11>

<T,B,22> <T,B,22>

Commit T×Commit T

#### Procédure de reprise



- Lecture du journal par le début
- Toute transaction ayant validé est refaite à partir du journal
- Toute transaction non validé:
  - Inscrire un <Abort T>
- Flush(): mise à jour du journal

### Procédure de reprise avec Check Point



- L'idée:
  - Le CKPT doit permettre de forcer l'écriture sur disque des transactions validées
- Caractéristique:
  - Le START CKPT n' est pas bloquant pour les nouvelles transactions
- Fonctionnement:

Début checkpoint

- Rechercher l'ensemble des transactions actives à l'instant t. Soit TA1,TA2,...,TAn cet ensemble
- Inscrire <START CKPT (TA1,TA2,...,TAn )>
- Flush buffer Log
- Rechercher les transactions ayant validé depuis le dernier CKPT. Soit TC=TC1,TC2,...TCm
- Pour chaque TCi
  - Rechercher les modifications effectuées (remonter jusqu' au premier CKPT où TCi non encore active)
  - Mise à jour des variables modifiées à partir du cache
- Inscrire <END CKPT> dans le fichier Log

End checkpoint

## Check Point pour la méthode REDO: Traitement de la panne



- Deux cas:
  - La panne après END CKPTi:
    - Transactions à refaire:
      - Toute transaction T active au <START>
        - Si commit alors REDO
        - Sinon abandonner les mises à jour
      - Les transactions ayant validé avant le début du checkpoint sont déjà prises en compte
  - La panne après START CKPT<sub>i</sub>:
    - La mise à jour sur disque pour les transactions validées avant le START CKPT<sub>i</sub> est incertaine.

#### Début

- Retrouver le START-END CKPT<sub>i-1</sub>
- Soit TA<sub>i-1,1</sub>,TA<sub>i-1,2</sub>,..., TA<sub>i-1,m</sub> l' ensemble des transactions ayant démarré après le START CKPTi-1 ou actives (non validées) au START CKPTi-1
  - Refaire toute transaction t ayant validé (commit dans le Log)
  - Abandonner les transactions n' ayant pas validé

# Exemple de reprise REDO avec Check point

- START T1
- START T2
- COMMIT T2
- START T3
- START CKPT (T1,T3)
- COMMIT T3
- END CKPT
- START T4
- COMMIT T4
- START CKPT(T1)
- START T5
- COMMIT T1



START T6

- COMMIT T6
- END CKPT

- Cas 1: Panne après commit T1
  - (T2 est validé)
  - Refaire T3,T4,T1,T6
  - Abandonner T5

- Cas 2: panne après END CKPT
  - (T4 et T3 validé)
  - Refaire T6,T1
  - Abandonner T5



#### **Journalisation UNDO/REDO**



- Pallie les défauts des méthodes précédentes:
  - UNDO: I/O inutiles
  - REDO: Monopolisation des buffers

Un nouveau type d'enreg: <T,A,Va, Vn>: mise à jour de la variable A par la transaction T, Ancienne valeur Va, nouvelle valeur Vn

Permet une indépendance entre l'inscription du commit dans le Log et entre les transferts disque

#### **Exemple**

Op/mem	Buf	Α	В	@A	@B
				10	20
Read(A,Buf)	10	10			
Buf+=1	11	10		10	20
Write(A,Buf)	11	11		10	20
Read(B,Buf)	20	11	20	10	20
, , ,					
Buf+=2	22	11	20	10	20
Write(,Buf)	22	11	22	10	20
Output A	22	11	22	11	20
Output B	22	11	22	11	22



cache

Sur disque

<Start T>

<T,A,10,11>

<T,B,20, 22>

<Commit T>

<Commit T>

# Procédure de reprise UNDO/REDO



- Commencer la reprise à partir du début du fichier Log
- Pour chaque commit rencontré,
  - Refaire les mises à jour à partir du log (même redondantes)

#### Exemple de reprise

- START T1
- START T2
- COMMIT T2
- START T3
- ...
- COMMIT T3
- ...
- START T4
- COMMIT T4
- ...
- START T5
- COMMIT T1
- START T6
- COMMIT T6
- ...

- Refaire:
  - T2,T3,T4,T1 et T6

Sens de la reprise

# Reprise UNDO/REDO avec points de contrôle



- L'idée: le point de contrôle permet d'anticiper sur les écritures pour libérer les buffers
- Description
  Début checkpoint
  - Rechercher l'ensemble des transactions actives à l'instant t. Soit TA1,TA2,...,TAn cet ensemble
  - Inscrire <START CKPT (TA1,TA2,...,TAn )>
  - Flush buffer Log
  - Vider les tampons
    - Ecrire sur disque toutes les mises à jour effectuées par
      - Les transactions actives
      - Les transactions validés entre deux checkpoints
  - Inscrire <END CKPT> dans le fichier Log
  - Flush Buffer Log

End checkpoint

# Fonctionnement des points de contrôle UNDO/REDO



- START T1
- <T1, A, 10, 20>
- START T2
- <T2, B, 1, 2>
- COMMIT T2
- START T3
- <T3, B, 2, 5>
- START CKPT (T1,T3)
- <T3, C, 1, 5>
- COMMIT T3
- END CKPT
- START T4
- <T4, B, 5, 6>
- COMMIT T4
- START CKPT(T1)
- START T5
- <T5,B,6,10>
- COMMIT T1
- START T6
- <T6,A, 20, 30>
- END CKPT
- COMMIT T6

- Pour le premier CKPT
  - A = 20
  - B = 5
- CKPT 2
  - C = 5
  - B = 6

# Checkpoint UNDO/REDO Cas de panne



- Description
  - Rechercher le dernier END CKPT
  - Toutes les transactions
    - ayant validé avant le START CKPT : rien
    - actives au CKPT,
      - si validé avant la panne :
        - completer la mise à jour sinon défaire les premières mises à jours
    - ayant démarré pendant ou apres le CKPT
      - si validé avant la panne :
        - Refaire
      - Sinon défaire

#### **Exemple**

- START T1
- <T1, A, 10, 20>
- START T2
- <T2, B, 1, 2>
- COMMIT T2
- START T3
- <T3, B, 2, 5>
- START CKPT (T1,T3)
- <T3, C, 1, 5>
- COMMIT T3
- END CKPT
- START T4
- <T4, B, 5, 6>
- COMMIT T4
- START CKPT(T1)
- START T5
- <T5,B,6,10>

Cas 2

COMMIT T1



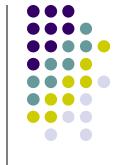
START T6 < T6, A, 20, 30 >



COMMIT T6

**END CKPT** 





- Cas 1: Le dernier CKPT est le CKPT1
  - C = 5; B = 6; A = 20
- Cas 2: Le dernier CKPT est le CKPT1
  - T1 est annulé donc A = 10
- Cas 3: dernier CKPT = CKPT2
  - Rien (Les maj de T1 sont déjà sur disque)
- Cas 4: dernier CKPT = CKPT2
  - A = 30

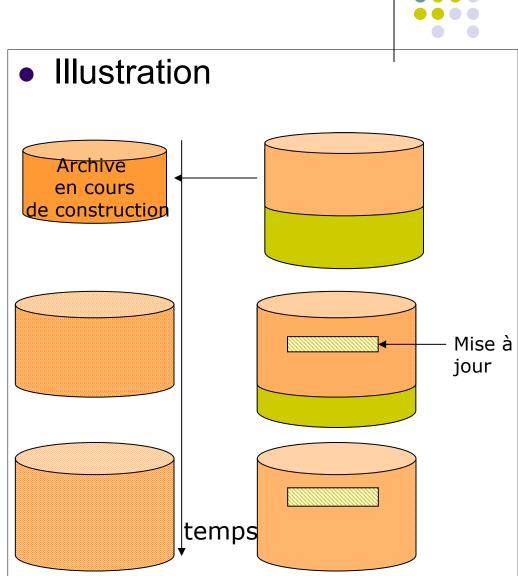
#### En conclusion



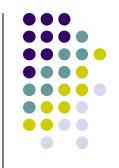
- La technique des Logs permet de retrouver un état cohérent en cas de panne mémoire
- Pas efficace en cas de crash disque
- Plusieurs techniques:
  - Archivage
  - Utilisation des disques tolérants aux fautes
  - Répartition

# Archivage des bases de données

- 2 types d'archives
  - archive intégrale
  - archive incrémentale
- Problème:
  - La base de donnée doit rester accessible pendant un archivage
- Restauration
  - Utilisation des logs



## RAID Redundant Array of Inexpensive Disks [Patterson 88]



#### RAID: Redundant Array of Inexpensive Disks

- tableau de disques peu coûteux pour améliorer les débits I/O
- cependant il faut introduire de la redondance

#### Niveaux de fonctionnement

- Redondance
  - Niveau 1 : Les Disques Miroirs
    - TANDEM Mirrored Disks
    - Conséquence: amélioration des lectures, espace de stockage :50%
    - Variante: mirroring assuré par le SGBD/SGF
  - Niveau 2 : une amélioration de RAID1 : seul un disque fonctionne en cas de lecture
  - Niveau 3 : Un Seul Disque de Contrôle par Groupe de Disque
  - Niveau 4 : Lectures et Ecritures indépendantes
  - Niveau 5 : Contrôle réparti sur les disques du Groupe
- Sans redondance
  - Niveau 0 : Stripping
    - répartition des blocs contigus d'un fichier entre les disques mais pas de redondance (ie AID)

## Niveaux de fonctionnement des RAID



- Redondance
  - Niveau 1 : Les Disques Miroirs
    - TANDEM Mirrored Disks
    - Conséquence: amélioration des lectures, espace de stockage :50%
    - Variante: mirroring assuré par le SGBD/SGF
  - Niveau 2 : une amélioration de RAID1 : seul un disque fonctionne en cas de lecture
  - Niveau 3 : Un Seul Disque de Contrôle par Groupe de Disque
  - Niveau 4 : Lectures et Ecritures indépendantes
  - Niveau 5 : Contrôle réparti sur les disques du Groupe
- Sans redondance
  - Niveau 0 : Stripping
    - répartition des blocs contigus d'un fichier entre les disques mais pas de redondance (ie AID)

#### Redondance multisites



- Préserve les données de pannes dues à des catastrophes naturelles
- Consiste à gérer plusieurs copies sur des sites différents.
- Variante:
  - Gestion de RAID sur plusieurs sites
  - Avec ou sans redondance